



Informe Ejecutivo de Analítica para los Negocios I

DETERMINANTES SALARIALES EN TALENTO

ALUMNOS:

MARTINA MORALES

MIGUEL ANGEL NOVA

IVANIA BECERRA

PROFESOR:

FRANCISCO ALFARO

Resumen ejecutivo.

TalentCo solicitó un análisis externo para entender qué factores determinan los salarios de sus empleados y validar si la asignación salarial es consistente entre departamentos, regiones y niveles de cargo. A partir de 9.803 registros depurados construimos un modelo de regresión lineal que explica aproximadamente el 56 % de la variabilidad salarial. Los hallazgos principales son:

- El nivel de cargo y los años de experiencia son las dos palancas dominantes; juntas explican la mayor parte del diferencial salarial.
- La educación formal agrega un premium claro, sobre todo para PhD (+US\$16K) y Master (+US\$7K) respecto a Bachelor.
- Ingeniería paga sustancialmente más que las áreas comerciales y de soporte (HR, Sales, Marketing), con brechas de US\$14K–19K.
- Las diferencias regionales son moderadas ($\pm$ US\$2-3K) y, en términos de negocio, secundarias frente a las anteriores.
- La brecha salarial por género a favor de empleados masculinos resulta estadísticamente significativa pero modesta en magnitud ($\approx$ +US\$1.8K). Justifica una revisión más profunda con datos complementarios.

1. Qué se hizo y por qué.

1.1 Datos de partida.

Se recibió un archivo `employee_compensation.csv` con 10.100 registros y 9 variables, las cuales se mencionan a continuación:

- ❖ Salario anual (Variable objetivo).
- ❖ Años de experiencia.
- ❖ Edad.
- ❖ Calificación de desempeño.
- ❖ Nivel educacional.
- ❖ Departamento.
- ❖ Región.
- ❖ Nivel de cargo.
- ❖ Género.

1.2 Limpieza de datos.

El dataset original presentaba problemas frecuentes en datos transaccionales de RRHH: categorías escritas con inconsistencia de mayúsculas ("Bachelor" vs "bachelor" vs "MASTER"), espacios sobrantes al inicio o final (" South", "Senior "), valores faltantes en varias columnas y filas duplicadas. Se aplicaron las siguientes correcciones:

- Duplicados: Se eliminaron las 97 filas exactamente repetidas.
- Texto: Se normalizó a formato Título y se corrigió manualmente PhD y HR.
- Salario faltante: Se descartaron las 203 filas sin salario informado. La variable objetivo no se imputa porque hacerlo sesgaría el modelo hacia los valores con los que se rellena.
- Resto de faltantes: Se imputó con la mediana (variables numéricas) o la moda (categóricas). Se prefirió la mediana sobre la media por ser más robusta a valores extremos.

El dataset final quedó con 9.803 filas, suficientemente grande para inferencia estadística confiable.

1.3 Enfoque analítico.

El trabajo se estructura en cuatro etapas complementarias:

- **Análisis exploratorio:** Para identificar distribuciones, asimetrías, valores atípicos y relaciones preliminares.
- **Pruebas de hipótesis:** Para validar formalmente, con un nivel de confianza del 95 %, si la experiencia y el nivel de cargo tienen un efecto real sobre el salario.
- **Modelo de regresión lineal multivariada:** Para cuantificar cuánto aporta cada factor al salario, manteniendo el resto constante.
- **Diagnóstico del modelo:** Verificación de supuestos (multicolinealidad, normalidad de residuos, homocedasticidad) para asegurar que las conclusiones son confiables.

2. Hallazgos del análisis exploratorio

Antes de modelar el salario, se exploró visualmente cómo se distribuye y cómo se relaciona con las principales variables. Estos gráficos guiaron las decisiones posteriores del modelo.

2.1 Distribución del salario




Figura 1. Histograma del salario anual con líneas de media y mediana.

La distribución salarial es asimétrica hacia la derecha: la mayoría de los empleados se concentra entre US\$70K y US\$110K, pero existe una cola larga de salarios altos que entrega la media (US\$95.8K) por encima de la mediana (US\$91.7K). Esta asimetría es típica en compensaciones — refleja a unos pocos empleados senior con remuneraciones muy superiores al grupo promedio.

2.2 Salario por nivel de cargo




Figura 2. Diagrama de caja del salario según nivel de cargo.

Las tres bandas (Junior, Mid, Senior) están bien separadas y prácticamente no se superponen en sus cuartiles centrales. Junior se ubica alrededor de US\$75K, Mid en torno a US\$95K y Senior cerca de US\$127K. La señal es clara: el nivel de cargo es uno de los principales separadores salariales en TalentCo. La dispersión dentro de Senior es mayor, lo que indica que, en ese tramo, existen diferencias individuales más marcadas (probablemente por experiencia y área).

2.3 Experiencia versus salario




Figura 3. Dispersión de años de experiencia vs. salario, coloreado por nivel de cargo.

Existe una relación positiva clara entre experiencia y salario: a mayor experiencia, mayor remuneración. La nube de puntos se separa también por color según el nivel de cargo, lo que ilustra que ambas variables están relacionadas, pero capturan dimensiones distintas: un empleado puede acumular experiencia sin subir de cargo. La línea de regresión de color negro confirma la tendencia ascendente.

2.4 Salario promedio por departamento



Figura 4. Salario promedio por departamento, ordenado de mayor a menor.

Se realizó también una comparación entre los salarios percibidos por los distintos departamentos de la empresa, donde se obtuvo que ingeniería lidera con holgura, seguido por Finanzas, Marketing, Sales y HR, en donde pagan salarios promedio considerablemente menores. Estas diferencias podrían reflejar:

- el mercado externo (los ingenieros son más caros de reemplazar)
- la composición de niveles (más Senior concentrados en Engineering)
- políticas internas heredadas.

El modelo de regresión permitirá aislar el efecto departamental "puro" — es decir, controlando por experiencia y cargo.

2.5 Correlaciones entre variables numéricas




Figura 5. Matriz de correlación de las variables numéricas.

Las correlaciones más relevantes son:

- **Salario y experiencia ($r \approx 0,56$):** Confirma cuantitativamente lo visto en el gráfico de dispersión.
- **Experiencia y edad (r alta):** Dos variables que crecen juntas casi en paralelo. Esto adelanta un problema de multicolinealidad que se abordará en el diagnóstico.
- **Desempeño y salario (correlación débil):** La calificación anual no es un predictor lineal fuerte del salario.

3. Pruebas de hipótesis

Una correlación visual no basta para afirmar que dos variables están realmente relacionadas en la población — podría ser ruido del muestreo. Por eso se aplicaron pruebas estadísticas formales con un nivel de significancia del 5 %.

3.1 ¿La experiencia determina el salario?

Hipótesis nula (H_0): los años de experiencia no tienen relación lineal con el salario.

Hipótesis alternativa (H_1): la experiencia está positivamente asociada con el salario.

Resultado: r de Pearson = 0,564, con un p -valor prácticamente igual a cero.

Conclusión: Se rechaza H_0 con holgura — la experiencia explica una parte significativa y positiva del salario. Este hallazgo, aunque intuitivo, era necesario validarlo formalmente antes de incorporarlo al modelo.

3.2 ¿Hay diferencia salarial entre Junior y Senior?

Se aplicó una prueba t de dos muestras independientes (Welch) comparando el salario promedio de Junior (US\$74.874) contra el de Senior (US\$127.013).

La diferencia de US\$52.139 anuales es estadísticamente significativa ($p \approx 0$). Esto formaliza lo que ya mostraba la Figura 2: las bandas de cargo no son etiquetas cosméticas, sino tramos salariales reales y diferenciados.

4. Modelo de regresión lineal

4.1 Preparación de variables

El modelo necesita variables numéricas. Para las categóricas se usaron dos técnicas:

- **Label Encoding:** Aplicado a Job_Level porque tiene un orden natural (Junior < Mid < Senior). Esto permite que el modelo capture el escalonamiento con un solo coeficiente.
- **One-Hot Encoding:** Aplicado a Education_Level, Department, Region y Gender (variables sin orden natural). Se eliminó la primera categoría de cada grupo (drop_first=True) para evitar redundancia matemática (trampa de variables ficticias).

Se dividieron los datos en 80 % entrenamiento y 20 % prueba (random_state = 42) para evaluar el modelo en datos que no vio durante el ajuste.

4.2 Resultados del modelo

La siguiente tabla resume los efectos cuantitativos estimados por el modelo (en US\$ anuales, manteniendo el resto constante):

Variable	Efecto (US\$/año)	Significativo ($\alpha = 5\%$)
Cada año adicional de experiencia	+625	Sí
Subir un escalón de cargo (Junior→Mid o Mid→Senior)	+20.910	Sí
Tener Master (vs Bachelor)	+7.165	Sí
Tener PhD (vs Bachelor)	+16.182	Sí
Trabajar en Finanzas (vs Ingeniería)	-4.323	Sí
Trabajar en HR (vs Ingeniería)	-18.870	Sí
Trabajar en Sales (vs Ingeniería)	-16.707	Sí
Trabajar en Marketing (vs Ingeniería)	-13.884	Sí
Región Norte (vs Este)	+2.688	Sí
Región Sur (vs Este)	-2.359	Sí
Región Oeste (vs Este)	+1.079	No ($p = 0,089$)
Género masculino (vs femenino)	+1.772	Sí ($p \approx 5,6e-5$)
Año adicional de edad	+160	Sí
Punto adicional en desempeño	+986	Sí

Métricas de desempeño del modelo:

Métrica	Entrenamiento	Prueba
MAE (error absoluto medio)	US\$6.814	US\$8.364
MAPE	11,5 %	15,2 %
RMSE	US\$19.417	US\$27.315
R ²	0,563	0,400
R ² ajustado	0,562	0,396

Lectura: El modelo explica el 56 % de la varianza salarial en entrenamiento y un 40 % en datos no vistos. La brecha entre ambos sugiere algo de sobreajuste, pero el modelo sigue siendo útil: predice el salario con un error típico de US\$8K en datos nuevos. El 44 % restante de varianza refleja factores no observables en los datos disponibles: habilidad de negociación individual, ofertas externas, antigüedad específica en TalentCo, etc.

5. Diagnóstico del modelo

Una regresión lineal supone ciertas condiciones sobre los datos. Si se violan gravemente, los coeficientes y p-valores pueden ser engañosos. Se revisaron las tres más relevantes.

5.1 Multicolinealidad (VIF)

El factor de inflación de la varianza (VIF) mide si dos predictores están demasiado correlacionados entre sí. Detectamos VIF elevados entre Age y Years_Experience, lo cual era esperable: rara vez un empleado acumula experiencia sin envejecer. Se decidió mantener ambas variables porque capturan dimensiones distintas (años calendario vs. tiempo profesional) y reconocer la limitación: los coeficientes individuales de cada una son menos confiables, pero las predicciones agregadas no se ven afectadas.

5.2 Normalidad de los residuos




Figura c. Histograma y Q-Q plot de los residuos del modelo.

El histograma de los residuos (lado izquierdo) muestra una forma aproximadamente acampanada centrada en cero, aunque con colas algo más pesadas que las de una normal perfecta. El Q-Q plot (derecha) confirma esta lectura, los puntos siguen la diagonal en la zona central y se separan ligeramente en los extremos. Con casi 8.000 observaciones, el Teorema Central del Límite asegura inferencia válida; no se considera un problema práctico.

5.3 Homocedasticidad (Breusch-Pagan)




Figura 7. Residuos vs valores ajustados.

El gráfico de residuos contra valores ajustados muestra un leve patrón de "abanico", la varianza de los residuos no es perfectamente constante a lo largo del rango salarial. La prueba de Breusch-Pagan confirma esta heterocedasticidad. La consecuencia es que los errores estándar clásicos podrían subestimar la incertidumbre real. Como mitigación se reportaron también errores estándar robustos (HC3) en el notebook; las conclusiones cualitativas no cambian.

6. Respuestas a las preguntas del negocio

6.1 ¿Cuáles son los principales determinantes del salario?

El nivel de cargo y los años de experiencia son los dos motores dominantes. La educación formal y el departamento agregan ajustes claros pero menores. La región, el desempeño y la edad tienen efectos pequeños una vez controlados los anteriores.

6.2 ¿Cómo impacta cuantitativamente la experiencia?

Cada año adicional de experiencia se asocia con aproximadamente +US\$625 anuales en salario, manteniendo el resto constante. Sobre una carrera de 15 años eso equivale a +US\$9.4K, sin contar promociones de nivel.

6.3 ¿Hay diferencias significativas entre departamentos y regiones?

Sí, en departamentos: HR, Sales y Marketing pagan entre US\$14K y US\$19K menos que Ingeniería en promedio. Finanzas queda más cerca (–US\$4K). En regiones, las diferencias son moderadas ($\pm$ US\$2-3K) y secundarias frente al efecto del cargo.

6.4 Promoción Mid → Senior: ¿cuánto aumenta el salario?

Según el modelo, un ascenso de Mid a Senior se asocia con un aumento esperado de aproximadamente US\$20.910 anuales, manteniendo experiencia y demás atributos constantes. Es la decisión salarial con mayor impacto directo que TalentCo puede tomar sobre un colaborador individual.

6.5 Recomendaciones

- **Formalizar bandas salariales:** Publicar rangos mínimo/máximo por cargo y experiencia. Reduciría la sensación de inequidad reportada por los empleados.
- **Auditar departamentos:** Validar si las brechas entre Ingeniería y HR/Sales/Marketing responden a precios de mercado externo o a inequidades internas heredadas. El diferencial es lo bastante grande como para justificar un benchmark externo.
- **Monitorear género:** La brecha de US\$1.8K detectada es modesta pero estadísticamente real. Recomendamos ampliar el análisis a bonos, promociones internas y ofertas iniciales antes de extraer conclusiones definitivas.

- **Transparentar el premium educacional:** Explicitar el premium por Master (+US\$7K) y PhD (+US\$16K) en las políticas internas refuerza la percepción de mérito.
- **Comunicación interna:** El modelo explica ~56 % del salario; el 44 % restante depende de factores no observados. Documentar los criterios que TalentCo sí controla (experiencia, cargo, educación, departamento) ayuda a recuperar confianza interna sin necesariamente revelar salarios individuales.

Anexo técnico

El detalle reproducible del análisis (código, salidas estadísticas completas, tablas de coeficientes con errores estándar y p-valores, pruebas de diagnóstico) se encuentra en el notebook `project_01.ipynb` adjunto. Las librerías utilizadas son `pandas`, `numpy`, `matplotlib`, `seaborn`, `scikit-learn`, `statsmodels` y `scipy`.